LSTM-ARO 簡報｜第 20–27 頁 研究筆記與講稿

> 依據：新版網頁簡報（共 27 頁）與論文原文；數字已對照論文 Table 7–11 重新核對。
> 建議時長：第 20–27 頁約 7–8 分鐘（30 分鐘論文報告中的後段）。

一、核心觀念速懂（被問到要能回答）

1. 四個評估指標（第 20 頁）

指標	公式	直覺	好壞
MSE	$(1/n)\,\Sigma\,(y-\hat{y})^2$	誤差平方後平均，大誤差被放大	越低越好
MAE	$(1/n)\,\Sigma\,\lvert y-\hat{y}\rvert$	平均差幾塊美元	越低越好
MAPE	$(100\%/n)\,\Sigma\,\lvert(y-\hat{y})/y\rvert$	平均差幾 %，可跨股價比較	越低越好
R^2	$1-SSE/SST$	模型比「猜平均值」好多少	越接近 1 越好，可為負

- **適應度用哪個指標，論文沒有寫。**Fig. 2 只畫出「用測試資料計算 accuracy and error → 回傳給 ARO 計算 fitness」。所以不要說「ARO 直接在優化 MSE」。
- MSE、MAE 有單位（美元²、美元），**不同股票不能直接加總比較**，所以用「逐檔數勝場」；MAPE 是百分比，才能跨股票比。
- MAPE 小提醒：論文公式有 ×100，但 Table 9 刊出的是小數比例（0.024 即 2.4%）。

2. 四項指標的勝出檔數（第 21 頁）

指標	LSTM-ARO	LSTM-GA	LSTM1D	LSTM2D	LSTM3D	ANN
MSE	**18**	10	2	0	0	0
MAE	**18**	11	1	0	0	0
MAPE	**18**	10	1	0	0	0
R^2	**19**	9	2	0	0	0

- 算法：每檔股票看哪個模型取得最佳值；同分時依論文表格的粗體為準。MAPE 有 1 檔（TRV）三個模型同為 0.017、論文未標粗體，所以總數是 29。
- 為什麼數勝場、不算平均誤差：UNH 股價約 500 美元、AAPL 約 150 美元，若把 MSE 加總平均，高價股會主導結果。逐檔比「誰最好」較公平。
- ARO 勝出的股票在各指標間大致相同，例如 MSE 與 MAE 的 18 檔只差一檔（INTC / KO 互換）。

3. 例外案例（第 22 頁）

股票	ARO MSE	GA MSE	ARO R^2	GA R^2	較佳
CAT	38.438	36.329	0.909	0.914	GA
CVX	23.970	21.953	0.911	0.919	GA
UNH	126.133	96.373	0.823	0.865	GA
AAPL	22.731	24.109	0.857	0.848	ARO（MSE 低 5.7%）
MSFT	63.322	79.253	0.892	0.865	ARO（MSE 低 20%）

可能原因（**皆為推論，非論文實驗證明**）：

- **沒有免費午餐定理（No Free Lunch）**：沒有任何最佳化演算法在所有問題上都最好。
- **個股特性**：CAT 景氣循環股、CVX 受油價與地緣政治影響、UNH 高價股絕對波動大。
- **單次實驗的隨機性**：論文沒有多次重跑，無法排除運氣成分。

4. 預測曲線（第 23 頁）

- 圖只能輔助觀察吻合程度，精確比較要回到 Table 7–10。
- 可留意：若預測線看起來像實際線往右平移一天，代表模型可能主要在沿用前一天的價格。這是股價預測常見的現象，但論文沒有量化，提出時要說是觀察，不是結論。

5. 時間成本（第 24 頁）

- 每次搜尋：50 隻兔子 × 50 代 = **2,500 次 LSTM 訓練評估**。論文沒說明 30 檔是各自搜尋還是共用一次搜尋，不要自行乘上 30。
- 搜尋耗時：ARO 754,890 秒（8.737 天）、GA 721,660 秒（8.353 天），ARO 稍慢約 4.6%。
- 推論（30 檔合計，Table 11）：ANN 136.5 秒 < LSTM1D 249.6 < GA 288.7 < **ARO 302.0（每檔約 10 秒）** < 2D 374.3 < 3D 501.5。
- 重點：**搜尋是一次性離線成本，推論才是日常成本**，兩者不能混為一談。

6. 討論（第 25 頁）

問題	內容
資料洩漏	Fig. 2 中，適應度直接取自測試集的預測誤差；同一份測試集又用來報告最終成績，結果可能偏樂觀。
搜尋預算不對等	LSTM1D / 2D / 3D 是固定架構、沒有調參；LSTM-ARO 經過 2,500 次訓練評估，優勢可能部分來自搜尋預算。
成分股與期間	用現行 30 檔成分股回測 2018–2022：DOW 於 2019 年 4 月才上市；AMGN、CRM、HON 於 2020 年 8 月才納入指數，有倖存者偏差。
再現性	未提供 epoch、batch size、正規化方式、GA 參數、各股最終超參數，也未說明是否多次重跑。

簡報沒寫、但可在 Q&A 補充：未使用 Walk-Forward 滾動驗證；模型只用收盤價（沒有成交量、大盤、總經或情緒指標）。「預測誤差低 ≠ 交易獲利」在第 26 頁結論。

二、講稿（約 7–8 分鐘）

Slide 20 | 評估指標（約 50 秒）

接下來看實驗結果。論文用四個指標衡量預測表現。MSE 是平均平方誤差，對大誤差特別敏感；MAE 是平均絕對誤差，可以直接理解成平均差幾美元；MAPE 是百分比誤差，方便跨不同價位的股票比較。這三個都是越低越好。R^2 是決定係數，衡量模型比單純猜平均值好多少，越接近 1 越好。

Slide 21 | 四項指標的勝出檔數（約 1 分鐘）

因為各股票價位差很大，直接平均誤差會被高價股主導，所以我們逐檔統計哪個模型的表現最好，並把四個指標放在同一張表。LSTM-ARO 在 MSE、MAE、MAPE 都拿下 18 檔，R^2 拿下 19 檔，大約六成；LSTM-GA 拿下 9 到 11 檔；固定架構只有 LSTM1D 偶爾拿下 1、2 檔，LSTM2D、3D 和 ANN 一檔都沒有。可以看到，經過自動調參的兩個模型拿下了絕大多數股票，而 ARO 又比 GA 多。

Slide 22 | 例外案例（約 1 分鐘）

不過我們不能說 ARO 全贏。先看 ARO 較好的例子：AAPL 的 MSE，ARO 22.7、GA 24.1，低了約 5.7%；MSFT 差距更大，ARO 63.3、GA 79.3，低了約兩成。但 CAT、CVX、UNH 三檔，不論 MSE 或 R^2 都是 GA 較好，其中 UNH 的 MSE，GA 96.4 明顯優於 ARO 的 126.1。可能的解釋有三：第一是最佳化領域的「沒有免費午餐定理」，沒有演算法能在所有問題上都勝出；第二是個股特性，例如 CVX 受油價影響、UNH 價位高、波動大；第三是論文只跑一次實驗，無法排除隨機性。這些是我們的推論，論文並沒有實驗證明。所以比較精確的說法是：ARO 在「多數」股票上表現最好。

Slide 23 | 預測曲線（約 40 秒）

這是論文中 AAPL 的預測曲線，左邊 ARO、右邊 GA。兩個模型都能貼近實際走勢，肉眼很難分出高下，所以精確比較還是要回到誤差表格。另外，股價預測常見的情況是預測線像是實際線往後平移一天，也就是模型很大程度在沿用前一天的價格；論文沒有針對這點做分析，這也是我們在討論時會提到的方向。

Slide 24 | 時間成本（約 1 分鐘）

接著是成本。ARO 用 50 隻兔子、迭代 50 代，一次搜尋就要訓練並評估 2,500 個 LSTM，總共花了 8.737 天；GA 在相同設定下是 8.353 天，ARO 稍慢一點。但要區分搜尋時間與推論時間。找到最佳參數後，LSTM-ARO 預測 30 檔只要約 302 秒，平均每檔 10 秒，介於 ANN 的 136 秒和 LSTM3D 的 501 秒之間。作者認為搜尋是一次性的離線工作，實務上可以接受。

Slide 25 | 討論（約 1 分 15 秒）

以下是我們閱讀後的評論，有四點。第一是資料洩漏：從論文 Fig. 2 可以看到，ARO 的適應度直接來自測試集的預測誤差，同一份測試集又被拿來報告最終成績，等於考前看過考題，結果可能偏樂觀。第二是公平性：LSTM1D、2D、3D 都是固定架構、沒有調參，而 LSTM-ARO 經過 2,500 次訓練評估，優勢可能有一部分來自搜尋預算。第三是資料範圍：論文用現在的 30 檔成分股回測 2018 年起的資料，但 DOW 2019 年才上市，AMGN、CRM、HON 2020 年才加入指數，有倖存者偏差。第四是再現性：論文沒有提供 epoch、batch size、正規化方式、GA 參數和各股最後選到的超參數，也沒有多次重跑。改進方向是用獨立的驗證集調參、讓基準模型享有相同的搜尋預算，並加入交易成本回測。

Slide 26 | 結論（約 50 秒）

總結這篇論文：作者用 ARO 自動搜尋 LSTM 的層數、神經元數、Dropout、優化器與學習率，以過去 20 天預測下一天，在道瓊 30 檔成分股、五年資料上比較六種模型。結果顯示 LSTM-ARO 在四項指標中都是勝出最多的模型，約 18 到 19 檔股票表現最佳。但代價是約 8.7 天的離線搜尋，而且價格預測誤差低，不等於扣除手續費和滑價後能獲利。再加上適應度取自測試集，結果可能偏樂觀，仍需要獨立驗證。一句話總結：這篇論文示範了用群體最佳化改善時間序列模型的超參數選擇，但驗證方式還需要更嚴謹。

Slide 27 | Q&A（約 20 秒）

以上是我們的報告，參考文獻列在畫面上。謝謝老師和各位同學，歡迎提問。

三、這段可能被問的問題

Q1：ARO 的適應度是用哪個指標？如果是 MSE，MSE 贏不是理所當然嗎？ 論文沒有寫明。Fig. 2 只畫出「用測試資料計算準確度與誤差」再回傳給 ARO。就算真的是 MSE，MAE、MAPE、R^2 也呈現相同趨勢，而且 GA 用的是同一套流程，兩者在相同基準上比較，ARO 勝出較多仍有意義。

Q2：適應度取自測試集有什麼問題？ 超參數是看測試集挑出來的，最後又用同一份測試集報告成績，等於考前看過考題，成績會偏樂觀。正確做法是另外切出驗證集來調參，測試集只在最後用一次。

Q3：ARO 比 GA 好的差距有統計顯著嗎？ 論文沒有做顯著性檢定，也沒有多次重跑，所以無法確定差距是否來自隨機性。這是重要限制。

Q4：預測線像是落後一天，代表什麼？ 代表模型可能主要在沿用前一天的價格。若拿「直接用昨天價格當預測」（naive baseline）來比，LSTM 的優勢可能沒那麼大；論文沒有提供這個基準。

Q5：為什麼 LSTM2D、3D 沒有比 1D 好？ 三者都是固定架構、沒有調參；只有約五年的日資料，層數增加可能過擬合。這反而支持論文論點：架構應依資料調整，而不是越深越好。

Q6：為什麼說有倖存者偏差？ 論文用現在的成分股回測過去五年。當時還不在指數裡的公司（DOW 2019 年上市；AMGN、CRM、HON 2020 年加入）被放進來，而 2020 年被剔除的公司（例如 XOM、PFE、RTX）不在樣本中。

Q7：8.7 天實務上可行嗎？ 一次性可接受；但市場結構改變就要重新搜尋。可以縮小兔群、減少迭代或加入 early stopping 來降低成本。

參考文獻

Gülmez, B. (2023). Stock price prediction with optimized deep LSTM network with artificial rabbits optimization algorithm. *Expert Systems with Applications*, 227, 120346. https://doi.org/10.1016/j.eswa.2023.120346